两个不同的目标：机器之心与人工智能的概念解绑

余玉桂
余玉桂战略研究室
they4897@gmail.com

2026 年 11 月 5 日

摘要

公共话语、产业路线图与学界的部分讨论，把机器智能与机器之心读成一条带里程碑的路：机器越智能，离“心”越近。本文从概念辨析的立场为相反的命题辩护：人工智能与机器之心是两个不同的目标，且这一差异是目的论的，不是形而上学的。前者的工程目标——服务于人类实践的功能智能——成功判据公开、密集、持续改进；后者的实现目标——心/意识结构在非生物基底上的真正实现，而非表现的模拟——被想象为可实现、被其研究共同体当作科学与工程来追求，但其判据问题至今没有共识性的第三人称答案。本文作出四项贡献。(1) 谱系考察表明两个目标各自独立成形并制度化：图灵的奠基性文本在确立行为判据的同时搁置了意识；机器意识成熟为一个拥有专属期刊、研讨会、学会与自身规范议程的独立领域；2022–2026 年间，一股“解绑浪潮”又从理论侧、评估侧与相关性侧分别汇聚到同一结论。(2) 给出“绑定”的四机制诊断：概念滑坡、叙事结构、商业激励、语言惯性。(3) 在目的论轴上陈述解绑主张——有别于 Searle 的形而上学式弱/强 AI 区分、Block 的属性区分、指标式评估框架与相关性论证——并以进步转账错觉为其核心推论：由于两个目标在话语中被焊死，可测量的能力进步被悄悄记作朝向心的进步；仅此一举就解释了公众对机器心的过度归属、能力里程碑处的人格恐慌、“AGI”的营销效力，以及反方向的——把得力工具贬斥为“不过是统计学”。(4) 陈述规范后果——双轨治理、工程目标无须等待心的判决即承载全部规范性、话语分栏——并给出证伪条款：何种发现将使两个目标重新合并。文末把这一主张安放进 AGI 人本拟合论之中：理论的边界条款一直在预设这一解绑。

关键词：人工智能；机器之心；机器意识；概念划界；目的论；进步转账错觉；人工智能治理；拟人化

1 引言

机器智能的每一次能力跃迁，在公共话语中都被当作朝向机器之心的一步。一个模型通过职业考试，人们问它的不是“它能为我们做什么”，而是“它理解吗”；新一代智能体发布，评论界重新翻开机器人格的卷宗。两种反应共享着一个很少被说出、因而很少被注意的假设：机器智能与机器之心是同一条带里程碑的路——能力进步，就其极限而言，就是朝向心的进步。赫拉利把这个根本错误命名为“智能与意识之间广泛存在的混淆”[1]；心理学家与计算机科学家已把它的公众形态记为“AI 意识错觉”[2]；计算机学会旗舰杂志的评论作者则从意识形态上把它点破——“功能主义被重新包装成技术宿命”[3]。

本文从概念辨析的立场为相反的命题辩护，并把它陈述为一条主张：**机器之心与人工智能是两个不同的目标**。我们将论证：人工智能的工程目标——服务于人类实践的功能智能——成功判据公开、密集、持续改进；机器之心的实现目标——非生物系统真正具有心，无论那需要什么结构——由其研究共同体以科学与工程（而不只是哲学）追求，但其成功判据至今没有共识性的第三人称测试。两个目标逻辑独立：一边的进步

既不构成另一边的进步，也不是另一边进步的尺度。二者的混淆不是无害的省事说法：它把能力收益记作心的收益，而且两个方向都在记——既把系统捧成“准人格”，又把工具贬斥为“不过是统计学”。

这一主张有一长串相近的论点，第 5 节逐一处理；但没有一个论点陈述过目标层面的分离本身。图灵搁置了意识，却没有宣告两个目标独立 [4]；Searle 区分了弱 AI 与强 AI，但那是关于恰当编程的计算机是什么的两种形而上学主张之争，而不是两项人类事业各自瞄准的目的 [5]；Block 把通达意识与现象意识作为属性分开 [6]；Chalmers 与十九人指标框架逐项审计系统的意识相关属性，却不问能力进步是否可以转账 [7, 8]。近期的解绑浪潮——功能等价而现象不等价 [9]、意识与智能无关 [10]、意识不取决于系统做了什么 [11]——已从三个不同侧面汇聚到同一条分界线，却尚未在公共混淆真正所在的那个层面把它综合起来：目标的层面。

这条主张要成为论文而不只是口号，须完成四件承重的工作。第一，两个概念必须有不循环的定义——机器之心不能定义为“人工智能尚未做到的东西”，智能也不能定义为“没有‘心’的心智”；每个定义必须援引各自的成功判据，来源独立于对方的对照（第 4.1 节）。第二，主张必须占据一条真正区别于前人的轴，否则新意就沦为复述（第 5 节）。第三，划界必须有实效：一条概念区分，只有当“合起来”与“分开来”会引出不同的后续判断时，才算立得住；我们将表明，“进步不可转账”这一句澄清至少改变四项后续判断（第 4.4、6 节）。第四，主张必须可反驳：我们陈述何种发现会使两个目标重新合并（第 8 节）。

贡献可压缩为四句话。谱系上，我们表明两个目标各自独立成形并制度化——分离是记录中的事实，不是提议（第 2 节）。诊断上，我们给出绑定的四个机制（第 3 节）。建构上，我们在目的论轴上以三个条款陈述解绑主张，以进步转账错觉为其操作性推论（第 4–4.4 节）。规范上，我们导出治理、工程与话语的后果，并陈述证伪条款（第 6–8 节）。第 7 节把主张安放进 AGI 人本拟合论——在那里，它一直被理论的边界条款预设着 [35]。

关于本文定位的一点说明。本文是一篇概念工程论文 [34]：它提议改变两个概念的使用方式——方向明确，理由可陈述。它不是意识理论综述，不是“机器之心不可能”的论证，也不是“机器之心可能”的论证。在形而上学上，主张刻意保持不可知；它唯一拒绝搁置的是目的论：两项事业各自为了什么，以及进步能否在二者之间转账。

2 两个目标，两部谱系

2.1 人工智能的工程目标

工程目标的奠基性文本，在创立的那一刻就搁置了心的问题。图灵 1950 年的论文被要求回答“机器能思考吗”，却用一个操作性判据——模仿游戏——替换了它；而当“来自意识的反驳”出现时（杰弗逊教授的反驳：任何机器都谈不上“能感受”），图灵的回应是把意识划出本题之外——这一划，从未被收回：

> “我无意给出这样的印象：我认为意识没有神秘之处。…但我认为，这些神秘之事未必需要先被解决，才能回答本文所关心的问题。”

这一划不是无足轻重的免责声明；它是工程目标的创立之举。论文放行的问题是行为与功能的——机器能否通过；论文搁置的问题是结构与现象的。五年后的达特茅斯提案确立了同一取向：“学习或智能的任何其他特征的每一个方面，原则上都可以被如此精确地描述，以至于机器可以被造出来模拟它”[12]。动词是“模拟”；成功判据是功能表现，从根上与内在状态的问题脱钩。此后使该领域制度化的一切——基准、排行榜、竞赛、资助判据、评测套件——都继承了这一取向：目标成功与否，取决于系统完成了什么，可公开核验、密集（成千上万个可测任务）、持续改进（指标逐年精细化）。判据如此的目标，可以追求、可以测量、可以资助，全程不必对心的问题表态。这不是领域的缺陷，而是它的构成原则。

2.2 机器之心的实现目标

另一个目标单独成形，自成一体，并建立了自己的机构与制度。非生物基底能否实现心/意识结构、实现的又是什么结构——这个哲学问题在当代有了自己的研究纲领：机器意识（machine consciousness）。这些机构比这轮 AI 热潮出现得更早：《意识研究杂志》2003 年的专题号 [13]，AISB 自 2005 年起的系列研讨会，Aleksander 与 Haikonen 的“意识机器”专著 [14, 15]，Gamez 与 Reggia 的领域进展综述 [16, 18]，2009 年创刊的专属期刊（《International Journal of Machine Consciousness》，2020 年起续办为《Journal of Artificial Intelligence and Consciousness》[17]），专属学会（数学意识科学协会 [20]），以及它自己的规范议程：Metzinger 呼吁全球暂缓“合成现象学”的研究 [19]。

该领域有两个特征在此至关重要。其一，其目标是结构性的，不是行为性的：机器意识文献问的是什么组织——循环加工、全局工作空间、高阶表征、整合的因果力——对心而言是充分的，而不是什么行为对基准而言是充分的。Reggia 的综述把领域动机说得毫不含糊：科学地理解意识，并“造出真正表现出意识觉知的机器”[18]——一个以觉知本身为成功判据的目标，而非任务表现。其二，其成功判据充满争议：最形式化的候选理论——整合信息理论——主张纯前馈系统（信号只单向传递、不带反馈回路）无论能力多强，其整合因果结构的测度为零 [21]；而该理论本身又在 2023 年被一封 124 人联署的公开信公开指为“伪科学”，并引来其辩护者的反批评。我们引这场争议不选边，而是把它当作相关事实的证据：机器之心问题是一个独立的战场，有自己的理论、自己的危机、没有共识性的第三人称判据——这恰恰说明它无法继承工程目标的那套指标。

2.3 解绑浪潮（2022–2026）

2022 至 2026 年间，这一分离获得了自己的文献，至少从四个侧面逼近。评估侧：Chalmers 审计大语言模型能否有意识，结论是当前系统不满足各指标属性，同时给十年内出现“意识的严肃候选”给出了不可忽略的概率 [7]；十九人指标框架的结论是“当前没有任何 AI 系统是有意识的”，同时未发现未来系统满足指标的明显障碍 [8]。理论侧：Tononi 团队的解绑结果——“两个系统可以在功能上等价而在现象上不等价”[9]：智能标度上的功能相等，心侧的不等——正是我们这条主张在形式层面的影子。相关性侧：意识与智能无关的论证，创造性与理解是机器原则上可实现的功能特性 [10]。诊断侧：“AI 意识错觉”[2]，以及“功能主义被重新包装成技术宿命”的意识形态批判 [3]。甚至有明确以意识为灵感的研究纲领，也把意识当工程素材而非目标——Bengio 的“意识先验”把意识用作架构思想 [22]。

中文哲学界不约而同地走到了这场分离的附近，但尚未在目标层陈述主张。赵汀阳问 AI 的危险在哪里，答：不在能力，在自我意识的可能——一条与能力基准完全不同的轴 [38]。何怀宏观察到，今日机器“仅仅在一个方面与人相似，即拥有高超的计算理性”，而全然没有自我意识 [39]。这是同一场分离的哲学直觉，尚无人从目的论上把它宣告出来。

2.4 缺失的宣言

记录显示的是：领域层面的分离早已制度化，文献层面的解绑正批量涌现——但“事情本身”没有被陈述过：两个目标独立；二者之间的绑定是一个有机制、可诊断的错误；任何一个方向的进步转账都未获授权。全部配料俱在，独缺综合——而综合恰恰要在公共混淆真正所在的层面完成。填补这一空缺即本文的贡献；最接近的论点，以及它们与本主张的差别各在哪条轴上，见第 5 节。断言“查无先例”，可靠与否取决于检索的覆盖面；检索日志见附录 A。

3 绑定：四机制诊断

若两目标独立，为何被读成一条路？绑定不是愚蠢；它是一个由四个相互强化的机制维持的稳定均衡。

M1：概念滑坡。 Searle 的弱/强区分——研究心的工具，还是字面意义上的心 [5]——本是为了把两种主张隔开。在接受中，区分塌掉了："人工智能"同时命名工程研究纲领（弱）与形而上学赌注（强），以致前者的证据被照例记作后者的证据。图灵测试遭遇互补的滑动：它作为明确搁置了意识的能力判据被提出 [4]，却被接受为心的测试，以致每个逼近它的系统都被读作在逼近心。

M2：叙事结构。 进步故事需要一个顶点。"机器在任务上越来越好"没有顶点，"机器向着心上升"有——而且文化用一百年为这个顶点备好了意象：机械人、人造人、觉醒的机器。赫拉利的大众写作既诊断了这一混淆，又重演了它：智能是情节线，意识是默认的终点 [1]。

M3：商业激励。 被拟人化的系统更好卖；心的光环比能力更能卖出溢价。一个被营销为"懂你"的系统，其转化率是一个被营销为"补全你的文本"的系统拿不到的。旗舰案例把这一结构摆得最清楚：宣告 GPT-4 出现"AGI 火花"的报告，全文检索不到任何对意识/感知的实质讨论[1] [23]——心的转账是由接受方完成的，不是由文本。品牌"AGI"之所以有效，正是因为它让能力里程碑沾上了心的光环；Jorge 与 Moreira 则从意识形态上把它点破：功能主义被重新包装成技术宿命，"把'机器做什么'与'我们希望它是什么'重新分开" [3]。

M4：语言惯性。 谈论对答如流的系统，日常词汇全是心智词：它"知道""想要""理解""思考"。Shanahan 的警告——这类用法不是无害比喻，而是概念混淆风险；关于文本生成系统的精确语言是科学必需 [24]——点出了载体：词语先于分析抵达，而词语一旦就位，它们夹带进来的本体论就成了常识。

四个机制，一个均衡：滑坡提供推理（能力证据即心的证据），叙事提供情节（上升），激励提供放大器（营销），惯性提供介质（词汇）。四个机制没有一个要求任何人相信假话；每一个只要求放任一条捷径站稳脚跟。这解释了绑定为何能在七十年的明确否认之下存活——从图灵的搁置到 Butlin 等的"当前没有任何 AI 系统是有意识的" [8]。

4 解绑主张

4.1 研究纲领、目标与成功判据

"目标"需要承载者与判据。承载者是研究纲领（program）：一项制度层面的事业，其边界由奠基性文献、发表阵地、资助渠道与路线图划定，而不由任何个体参与者的信念划定。一个实验室可以同时追求两个研究纲领；主张关心的是两个目标之间的逻辑关系，而不是能不能同时追求。目标的判据是其成功条件：世界的什么状态算作该研究纲领的成功。研究纲领凭成功条件自立为一——这使我们无须诉诸心理学就能谈论两个研究纲领是否同一个。

目标一：人工智能的工程目标。 成功条件是完成那些由人来做时需要智能的任务。其判据是行为性的、公开的（通过、求解、生成、辅助）；密集（成千上万个可测任务）；持续改进（基准与评测套件逐年精细化）。该目标在制度上对心不可知：成功条件中没有任何一条要求内在状态，也没有任何一条排除内在状态。定义取自研究纲领自身的创立之举——图灵的操作性判据 [4]、达特茅斯的"模拟" [12]——而非与目标二的对照。

[1] 对全文的关键词穷举：正文零处出现意识相关词；"feelings"仅出现于一段 GPT-4 对话样例与一条参考文献标题内 [23]。

目标二：机器之心的实现目标。 成功条件是心/意识结构在非生物基底上的实现——系统不仅表现得像有心，而且有心，其意义由某个意识理论指定：整合因果力 [21]、全局工作空间、高阶通达、循环加工。其判据是结构性的而非行为性的，在诸理论间充满争议，且目前没有共识性的第三人称测试；指标框架的清单 [8] 是归属的启发式，不是检验手段。定义同样取自机器意识研究纲领的自我表述——Reggia 的“造出真正表现出意识觉知的机器”[18]——同样不靠与目标一的对照。

这样，两个定义都避开了循环：各自援引本研究纲领的奠基性文献与本目标的成功判据。同时注意判据不对称的含义（第 4.5 节将把它用作解释）：目标一的成功可按公开的标准核查；目标二的成功——若还有核查可言——只能由一个尚不存在且无争议的理论核查。一个目标有记分牌；另一个有一场关于记分牌是否可能的争论。

4.2 主张：三个条款

P1（独立性）。 目标一的进步既不构成目标二的进步，也不是目标二进步的尺度。能力收益不是心的收益——在任何规模上、无论跑多远都不是。

P2（双向不可转账）。 目标一的进步，对目标二不产生任何承诺、义务或程序上的资格：能力里程碑不自动开启人格、权利或道德地位的程序。反过来，目标二的任何判决不约束目标一的许可或价值：“它永远不能真的理解”不是反对一件工具的论证——意识并非机器智能的必要条件，使用中真正要紧的功能特性——解题、创造、作为能力的理解——原则上无须意识即可实现 [10]。

P3（可重组性）。 两个目标可以被独立追求，也可以被联合实现。二者有分别，不互相排斥；因此，风险分析必须盯住的正是组合——工程目标所追求的能力，与心侧所追求或被授予的地位——而不是把能力里程碑读作心的里程碑。绑定让人把“不是同一个目标”听成“不能同时出现”；这条主张把两者拆开。

4.3 最强解读：功能主义的桥接原理

绑定有一种哲学上可敬的辩护，必须正面迎战而不该嘲笑：计算功能主义。若某一类恰当的功能组织就足以产生心，那么足够的功能成就就是心的成就，两个目标依定理重新合并。三条回应。

第一，这条桥接原理（bridge principle，科学哲学中把两个理论的语汇连接起来的定律）是有争议的理论，不是既成事实。最形式化的意识理论明确否认这座桥：在整合信息理论下，两个系统可以“功能等价而现象不等价”，能力再强的前馈系统——正是缺了那道反馈回路——整合结构也为零 [9, 21]。可以拒绝该理论；但不可以把否定该理论当作已确立的事实来用——该领域自己都把问题当作开放的 [8]。把一个有争议的形而上学当作工程用的桥接原理，恰恰是“功能主义被重新包装成技术宿命”[3]。

第二，即使某种功能主义为真，一个理论被还原到另一个理论，也不会把两个研究纲领合并成一个。若化学还原为物理，制药目标并不因此变成粒子物理的目标；成功判据仍然有别，还原提供的是两种成功之间被发现的关系，不是目的的同一。未来若发现功能与现象之间的桥接原理，那将是关于目标二的一项发现——也许要靠目标一那种水平的工程才做得出——而不是两个目标的合并。

第三，功能主义填不平这道评估的鸿沟：即使是功能主义者，眼下也拿不出一种共识性的第三人称检验手段。Chalmers 给出的是概率；指标框架给出的是一份启发式清单 [7, 8]。一个成功判据是有争议理论的目标，并不因此就变得可以用另一个目标的指标来测，至多只能把它测得很差。

4.4 进步转账错觉

下面看这条主张如何兑现。定义**进步转账错觉**：把测量到的目标一进步，系统性地记作目标二进步——凡两个目标被绑定之处，话语就执行这一记账。这个错觉不是虚设的靶子——它就是每一次能力跃迁的默认

读法。给它命名、对它说“不”，四项后续判断就会跟着改变。

(a) 公众的过度归属，原来是一笔记错的账。 言语的流畅触发对心的归属，这一点已被记为“AI 意识错觉”，风险有名有姓——操纵、过度信任、政策混乱 [2]。转账错觉给出其结构：公众不是愚蠢地从行为推出心；公众正确地登记了目标一的进步，又把它错记到目标二头上——因为账本只有一栏。纠错的办法不是嘲讽，是一本双栏账本。

(b) 里程碑处的人格恐慌失去导火索。 每一代能力都重新点燃人格与权利之争——这一模式从欧洲议会的“电子人”决议 [25] 与随后的专家拒绝，一路跑到每个模型发布日的周期性重提。在 P2 之下，能力里程碑根本不是开启此类程序的那一类事件：地位问题是制度—法律行为，有自己的判据 [31, 32]，不是基准分数的自动后果。里程碑理应触发的只是对福祉相关属性的评估——那是目标二侧的工作，在自己的轨道上 [28, 29]——而不是授予地位的审议本身。

(c) “AGI” 营销失去光环。 这个品牌管用，靠的正是转账：能力里程碑借“心”的光环，而这笔借贷却从不入账。解绑并不禁用这个词；它把发票逐项开列——写明所主张的究竟是什么，任务表现，还是对心的接近——而 Sparks 案例表明二者可以在旗舰话语里脱钩：文本宣告的是能力“火花”，接受方听到的是心的接近，而文本自身对心根本未置一词（第 3 节 M3）。

(d) 反向转账挡住贬斥。 绑定是双向的：同一场融合，既把系统捧成准人格，也任人贬斥它们——“它不过是统计学，并不真的理解，因此一文不值”。P2 对此同样一刀：若意识并非机器智能所必需，理解作为能力是机器可实现的功能特性 [10]，则“没有心”构不成对一件工具价值的判决。解绑在设计上就是一把双刃剑：既给吹捧泄气，也给贬斥泄气。

4.5 评估的不对称：绑定为何稳定

错觉为何能在七十年的否认之下持续？因为第 4.1 节指出的不对称。目标一产出一连串密集、公开、持续改进的可测成功；目标二按其本性产出一场关于判据的争论。一个有记分牌的目标与一个没有记分牌的目标，无法稳定地共享一套话语：有记分牌的一方会侵占没有记分牌一方留下的真空。能力指标永远在场、永远可引、永远在涨；心的问题没有任何一种其判决会被接受的检验手段 [8, 21]。因此绑定不只是错误，而是生态：测得出的进步流向测不出的目标，因为测不出的目标无法拒收这种货币。这也解释了第 3 节诊断出的机制为何轻易找到落点——它们无须创造转账，只须不去打断它。图 1 为这幅图景定格。

5 各有各的轴：五个既有的区分与目的论轴

主张必须与五个相邻的区分划清界线——每个区分都在自己的轴上，把智能与心分开。表 1 压缩了比较；本节给出论证。

Searle（1980）：形而上学轴。 弱 AI 对强 AI，是关于恰当编程的计算机是什么的两种主张之间的区分——研究心的工具，或字面意义上的心 [5]。它是一条“存在”之轴，且以否定方式论证——著名的思想实验“中文房间”就是为击破强 AI 而设。目的论轴是“目的”之轴：两项事业为了什么，进步能否转账。这一区别并非咬文嚼字。Searle 的区分被形而上学扣作了人质：一旦“中文房间”论证被驳倒，弱/强之分就会跟着模糊。而本主张在任何形而上学结局下都存活——即使某种功能主义为真，仍有两个判据有别的研究纲领

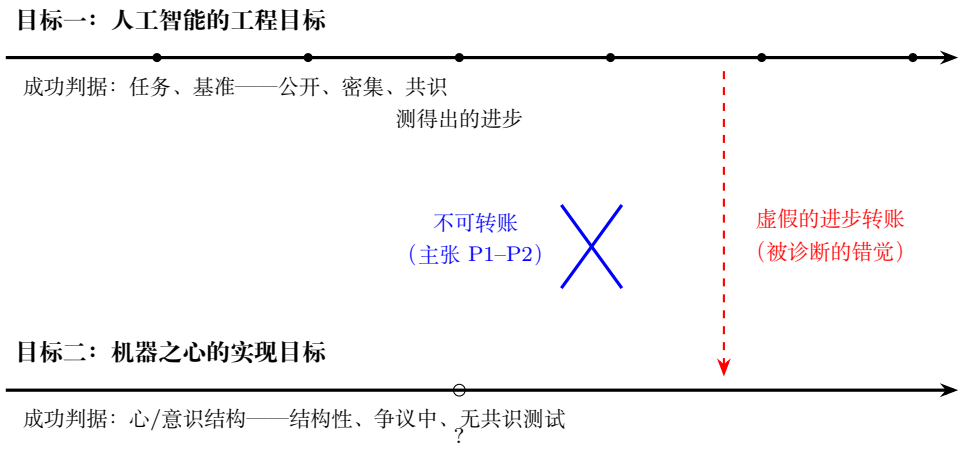


图 1: 绑定与解绑。两个目标，判据各自独立；红色虚箭头是话语默认执行的转账（第 4.4 节）；蓝色叉箭头是主张的 P1–P2（第 4.2 节）。评估的不对称（第 4.5 节）解释箭头的方向：测得出的目标向测不出的目标出借自己的货币。

（第 4.3 节）。反过来，即使 Searle 的否定论证成立，它确立的也只是句法不产生语义；它对进步的记账只字未提——而那才是公共混淆真正所在之处。

Block（1995）：属性轴。 通达意识与现象意识的区分，分开的是系统的两种属性，Block 的诊断——认知科学系统性地把一者的功能与另一者的本性混在一起 [6]——是我们绑定诊断的前身。但属性区分只给系统的状态分类；它划不出研究纲领及其目的的界线。绑定的辩护者可以全盘接受 Block 的区分，同时主张目标一的进步正在接近现象能力。主张所否认的恰是后一个合取支。

Chalmers（2023）与 Butlin 等（2023）：评估轴。 指标框架问的是*给定系统具有哪些意识相关属性*，并断定当前系统均无意识 [7, 8]。这是归属的技术——必要，且在操作上预设分离（心与能力分开审计）。但对系统的评估仍不是目标之间的关系：框架的结论与绑定读法“我们离‘心’的距离为零、而能力进步正是我们的抵达方式”完全相容。主张否认的恰是后半个分句。

Seth（2025）：认识论轴。 Seth 论证意识不是系统*做了什么*的问题——反对“计算足矣”假设 [11]。这是与我们诊断的那一步最接近的先例：公众从‘做’滑到‘是’。差别在于：Searle 式修正（此处为 Seth 的修正）是认识论的（凭什么归属），我们的是目的论的（进步在研究纲领之间如何记账）。他的靶子是一个推理；我们的靶子是一本账。二者可复合：Seth 挡住从行为到心的推理；我们这条主张挡住从能力进步到心进步的转账，并附加认识论归属理论所不附带的规范后果。

Pesonen 与 Reijula（2026）：相关性轴。 他们论证意识与智能不相关、创造性与理解是原则上可实现的功能特性 [10]，在属性层面确立了独立性的一个方向：智能不需要意识。我们在三个方向上推广：双向（对心的判决也不约束智能的价值）；目标层（研究纲领与成功判据，不是属性）；规范性（对治理、工程、话语的后果）。

以另一种方式相邻的还有：AGI 定义传统把通用人工智能定义为跨域能力、意识非必要条件 [40]——一次从未被明确立为主张的隐含解绑，其后果是这个词后来得以在商业上把两个目标重新焊起来（第 4.4 节 c）。

区分	轴 / 问题	目的论轴添加了什么
Searle 1980：弱 vs. 强 AI	形而上学：编程的计算机是心吗?	关于研究纲领的目的而非系统的存在；任何形而上学结局下都存活；靶子是进步的记账而非语义。
Block 1995：通达 vs. 现象	属性：是哪一种意识?	按成功判据给研究纲领划界，而非按类型给状态分类；挡住属性区分够不到的目标层滑动。
Chalmers 2023；Butlin 等 2023	评估：此系统有哪些指标属性?	对系统的心的归属，与“能力进步接近心”的主张可分；否认后者。
Seth 2025	认识论：归属的依据是什么?	拦截的不止从行为到心的推理，还有进步的转账；携带治理层面的规范后果。
Pesonen & Reijula 2026	相关性：智能需要意识吗?	双向、目标层、规范；既给吹捧泄气，也给贬斥泄气。
本文	目的论：各研究纲领的成功由什么构成? 进步可否转账?	—

表 1: 五个既有的区分与本文的轴。每个相邻的区分都在自己的轴上把智能与心分开；没有一个陈述过两个目标的独立性，或诊断过它们之间的进步转账。

而在机器意识内部，目标结构本身是活跃论题——Reggia 的两个动机 [18]、按研究目标给机器意识分类的新近综述 [41]——但那是目标二的内部目标剖析，不是目标二与目标一之间的划界。

6 后果

6.1 治理：双轨原则

主张的治理推论是结构性的：*能力监管与心侧评估是不同轨道、不同手段；一条轨道上的事件不自动开启另一条轨道上的程序。*轨道分离已是制度实践的既成事实，等着它的原则到来。欧洲议会曾提议为自主系统探讨“电子人格”[25]；150 余名专家公开拒绝这一范畴 [26]，委员会未采纳；而 AI 法案——本时代的中心监管文件——监管能力与风险，对人格与意识不置一词 [27]：一次隐含的解绑。心侧，一条福祉评估轨道已独立地生长起来——认真对待 AI 福祉的研究纲领 [29]，以及第一批公司报告，其自我表述恰是主张之下的正确姿态：“对当前或未来 AI 系统能否有意识，没有科学共识”，以谦逊切入 [28]。产业界的同向声明——AI 是可亲的工具，永不是人 [30]——从能力侧宣告了解绑。主张给这些实践补上的是它们正确的*理由*：里程碑不是用来购买地位的正确货币；地位是制度性的授予行为，有自己的判据，而道德地位从来不由智商决定 [31, 32]。在双轨原则下，能力里程碑可以触发*评估*，永不默认触发*地位授予的审议*。

6.2 工程：无须心的判决，规范责任一项不少

第二条推论一刀同时切断工程师最爱的借口与批评者最爱的武器。工程目标担起其全部规范责任——安全、可靠、可审计、服务于人类实践——而无须等待心的问题：“没有意识”不是合规通行证，“可能有心”也不是升级证书。镜子批判让第一刀锋利：对答如流的系统，其危险不在于它感受，而在于它反射——通过它映回的东西重构人对自身的理解 [33]；这一危险在目标一自己的账本上就已全部在场。AGI 人本拟合论让第二刀精确：目标一的*用途*是拟合人类实践——人们做什么、尝试什么、在哪里失败、如何纠正的全谱与全

程 [35, 37]——这个对象可定义、可审计、可改进，全程无须涉及现象状态。工程目标既不需要心的判决，也不被心的判决豁免。

6.3 话语：从词汇纪律到分栏报道

若两个目标有分别，Shanahan 的词汇纪律 [24] 就不再是文体偏好，而是关乎记账对错的问题：对目标一系统的心智习语是记串了栏的账——把能力记到它并不来自的一栏。对新闻与机构传播的操作性推论是分栏：能力主张与心主张分栏报道，各自携带各自的证据类型——前者用基准，后者用指标审计或理论。这恰恰是计算界内部早已发出的呼吁：把“机器做什么”与“我们希望它是什么”重新分开 [3]。

6.4 对机器之心研究纲领自身

解绑不是反心的立法；它保护机器之心研究纲领不被俘获。当它与目标一绑在一起时，机器之心或者充当营销道具（有了这个顶点，整条路才好卖），或者充当终点神话（用它贬低路上的每一站）。解绑之后，它就回到其文献一贯的自我理解：一个拥有结构性成功判据的哲学与科学研究纲领，有权主张自己的暂缓 [19]，有权提出自己的加速论证 [20]，向意识科学负责而不向能力基准负责。一个成功判据尚在争论的研究纲领，值得比“有人替它借来一张记分牌”更好的待遇。

7 在 AGI 人本拟合论中的位置

AGI 人本拟合论——本文所属的研究纲领——自其边界条款写下之日起就在预设这一解绑：拟合功能性人格结构，永不拟合现象状态，永不授予人格地位 [35]。这些条款是对“可拟合什么”的停止条件；从目的论角度读，它们是一个理论之内相互隔开的两个目标：人类实践需要系统交付的一切，都能在功能账本上交付；现象账本不是理论有权书写的。理论此前对危险的读法——危险的组合是地位 × 能力，而非能力本身 [35]——正是 P3 的缩影：两个独立变量，一个需要治理的组合。本文为这一研究纲领补上的，是该预设的明确而不依赖理论的表述：一段从两个研究纲领自身记录出发的论证（第 2 节）、一份机制诊断（第 3 节）、一个操作性错觉（第 4.4 节）、若干后果（第 6 节）与证伪条款（第 8 节）——使边界条款不再立于一条未说出的公理之上。同族的失败数据审计与数据方法论 [36, 37] 为目标一提供现成的活教材；本文为整个研究纲领画出“哪个目标是哪个”的地图。

8 证伪条款与局限

一条不可反驳的概念主张只是口号。三类发现将击败或降级本解绑。

R1（发现桥接原理）。 若现象意识被证明对通用智能必要——与当前论证相反 [10]——则两个目标功能性重新合并：追求目标一即是间接追求目标二，P1 在极限处失败。注意什么存活：P2 的制度要点（地位被授予，不被基准测出）不依赖 P1，即使合并发生也仍作为治理而留存。

R2（发现检验手段）。 若机器之心的共识性第三人称判据出现——被接受的检验手段，而非启发式清单 [8]——评估的不对称随之瓦解：目标二获得记分牌，虚假转账失去其生态位（第 4.5 节），主张只剩下一桩制度史上的事实。这是三条中我们认为在数十年尺度上最有可能到来的一条——而它的到来将是心侧研究纲领的成功，不是能力进步的成功。

R3（发现创立意图）。 若创立时期的文献表明 AI 事业在制度上致力于造心——而非完成智能功能——则我们对绑定的诊断需修订为“目的继承”的诊断。记录指向另一边：图灵的搁置 [4] 与达特茅斯的“模拟” [12] 都在功能上确立该目标；绑定是后来获得的（第 3 节），不是继承的遗产。

局限。 主张划界所针对的是制度化的研究纲领，不是意图：它对任何实验室私下瞄准什么不作任何断言。它是概念—规范性的，不是经验性的：本文之内没有实验为它作证；记录与错觉的被解释项就是它的证据。它在形而上学上刻意保持不可知：对机器之心是否可能、哪个意识理论为真、当前系统有无任何形式的经验，均不采取立场——这些问题划归心侧轨道——那才是它们该在的地方。

9 结论

记录显示两个研究纲领：各自成形，各自制度化，以不可通约的判据测量成功；话语显示一条带里程碑的路，把每一次能力收益都记作朝向心的一步。本文把这一校正陈述为主张——两个不同的目标；进步不可转账——给绑定以机制层面的诊断，表明这一校正在四项后续判断上见实效，以五个卓越的相邻区分为参照，为这条新轴辩护，导出其治理、工程与话语后果，并陈述反驳它的条件。解绑不需要新实验，不需要形而上学；它需要一本双栏账本，以及保持它的纪律。概念工作在这里一如往常，是提早完成的治理工作：话语融合了什么，制度就继承什么——而融合的代价——被捧高的系统、被贬低的工具、未定价的营销、为时过早的地位之争——已经在偿付。本文在这一研究纲领中的位置，是把 AGI 人本拟合论一直在用的那条公理挑明：拟合对象是实践，在功能账本上；心是另一个目标，在另一本账上——两本账对不上。

A 先例检索日志

第 2.4 节关于新意的断言是相对于检索而言的，在此记录。目标层主张的精确短语英文检索（“the goal of AI is not consciousness”、“artificial consciousness is not the goal of AI”、“machine consciousness as a research program distinct from AI”）在同行评审文献中零命中。已发现并整合的最接近论点：Searle[5]（形而上学轴）；Seth[11]（认识论轴）；Reggia[18]（机器意识内部的两个动机）；AGI 定义传统 [40]（隐含而从未明确立为主张的解绑）；Qin 等 [41]（目标二的内部目标解剖）。两个事件因原始文件是公开信而非出版物而在正文中随文引用、无文献条目：2023 年整合信息理论“伪科学”公开信（124 人联署，2023 年 9 月）与 2018 年 150 余名专家反对欧洲议会“电子人格”范畴的公开信 [26]；二者均经多个独立二手来源核实确有其事。此处的“查无”结论相对于公共网络与学术索引的检索成立；中文库（CNKI）内部对中文里同一形式陈述的检索尚未完成，已在第 2 节相应标注。

参考文献

[1] Harari, Y. N. (2024). *Nexus: A Brief History of Information Networks from the Stone Age to AI*. Random House.

[2] Elmoznino, E., & Bengio, Y. (2025). Illusions of AI consciousness. *Science*, 389(6765), 1090–1091.

[3] Jorge, J., & Moreira, C. (2026). AI is a harsh mistress: On anima machina, herd acceptance, and the politics of conscious machines. *Communications of the ACM*, 69(8), 29–31.

[4] Turing, A. M. (1950). Computing machinery and intelligence. *Mind*, 59(236), 433–460.

[5] Searle, J. R. (1980). Minds, brains, and programs. *Behavioral and Brain Sciences*, 3(3), 417–424.

[6] Block, N. (1995). On a confusion about a function of consciousness. *Behavioral and Brain Sciences*, 18(2), 227–247.

[7] Chalmers, D. J. (2023). Could a large language model be conscious? arXiv:2303.07103.

[8] Butlin, P., Long, R., Elmoznino, E., Bengio, Y., Birch, J., Constant, A., Deane, G., Fleming, S. M., Frith, C., Ji, X., Kanai, R., Klein, C., Lindsay, G., Michel, M., Mudrik, L., Peters, M. A. K., Schwitzgebel, E., Simon, J., & VanRullen, R. (2023). Consciousness in artificial intelligence: Insights from the science of consciousness. arXiv:2308.08708.

[9] Findlay, G., Marshall, W., Albantakis, L., David, I., Mayner, W. G. P., Koch, C., & Tononi, G. (2024). Dissociating artificial intelligence from artificial consciousness. arXiv:2412.04571.

[10] Pesonen, R., & Reijula, S. (2026). Consciousness, creativity, and understanding are not obstacles to machine intelligence. *Synthese*, 208, Article 2.

[11] Seth, A. K. (2025). Conscious artificial intelligence and biological naturalism. *Behavioral and Brain Sciences*, 49, e315.

[12] McCarthy, J., Minsky, M. L., Rochester, N., & Shannon, C. E. (1955). A proposal for the Dartmouth summer research project on artificial intelligence. AI Magazine, 27(4), 12–14 (reprinted 2006).

[13] Holland, O. (Ed.) (2003). Machine consciousness [Special issue]. *Journal of Consciousness Studies*, 10(4–5).

[14] Aleksander, I. (1996). *Impossible Minds: My Neurons, My Consciousness*. Imperial College Press.

[15] Haikonen, P. O. (2003). *The Cognitive Approach to Conscious Machines*. Imprint Academic.

[16] Gamez, D. (2008). Progress in machine consciousness. *Consciousness and Cognition*, 17(3), 887–910.

[17] World Scientific (2020). Journal of Artificial Intelligence and Consciousness (continuing the International Journal of Machine Consciousness, est. 2009). https://www.worldscientific.com/worldscinet/jaic

[18] Reggia, J. A. (2013). The rise of machine consciousness: Studying consciousness with computational models. *Neural Networks*, 44, 112–131.

[19] Metzinger, T. (2021). Artificial suffering: An argument for a global moratorium on synthetic phenomenology. *Journal of Artificial Intelligence and Consciousness*, 8(1), 43–66.

[20] Association for Mathematical Consciousness Science (2023). Open letter: Include consciousness science in AI governance. https://www.amcs-community.org

[21] Albantakis, L., Barbosa, L., Findlay, G., Grasso, M., Haun, A. M., Marshall, W., Mayner, W. G. P., Zaeemzadeh, A., Boly, M., Juel, B. E., Sasai, S., Fujii, K., David, I., Hendren, J., Lang, J., & Tononi, G. (2023). Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms. *PLOS Computational Biology*, 19(10), e1011465.

[22] Bengio, Y. (2017). The consciousness prior. arXiv:1709.08568.

[23] Bubeck, S., Chandrasekaran, V., Eldan, R., Gehrke, J., Horvitz, E., Kamar, E., Lee, P., Lee, Y. T., Li, Y., Lundberg, S., Nori, H., Palangi, H., Tulio Ribeiro, M., & Zhang, Y. (2023). Sparks of artificial general intelligence: Early experiments with GPT-4. arXiv:2303.12712.

[24] Shanahan, M. (2024). Talking about large language models. *Communications of the ACM*, 67(2), 68–79.

[25] European Parliament (2017). Resolution of 16 February 2017 with recommendations to the Commission on Civil Law Rules on Robotics, P8_TA(2017)0051.

[26] Bryson, J., et al. (2018). Open letter to the European Commission: Artificial intelligence and robotics (150+ signatories).

[27] European Union (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).

[28] Anthropic (2025). Exploring model welfare. Research statement, 2025-04-24. https://www.anthropic.com/research/exploring-model-welfare

[29] Long, R., Sebo, J., et al. (2024). Taking AI welfare seriously. arXiv:2411.00986.

[30] Suleyman, M. (2026). Public statement set on AI as personable tools, never persons. Original post, reported by Reuters, 2026-09-16.

[31] Bostrom, N., & Yudkowsky, E. (2014). The ethics of artificial intelligence. In K. Frankish & M. Ramsey (Eds.), *The Cambridge Handbook of Artificial Intelligence* (pp. 316–334). Cambridge University Press.

[32] Gunkel, D. J. (2018). *Robot Rights*. MIT Press.

[33] Vallor, S. (2024). *The AI Mirror: How to Reclaim Our Humanity in an Age of Machine Thinking*. Oxford University Press.

[34] Cappelen, H. (2018). *Fixing Language: An Essay in Conceptual Engineering*. Oxford University Press.

[35] Yu, Y. (2026). Fitting the practice, not the works: A human-referential theory of AGI. Zenodo. doi:10.5281/zenodo.23391808

[36] Yu, Y. (2026). Success provides direction, failure provides precision: A structured audit of failure data in LLM training. Zenodo. doi:10.5281/zenodo.23355929

[37] Yu, Y. (2026). Fitting the practice: A data methodology for frontier model training, with a readiness audit of 2026 flagship pipelines. Zenodo. doi:10.5281/zenodo.23488466

[38] 赵汀阳（2019）. 人工智能的自我意识何以可能?. 《自然辩证法通讯》, 2019 年第 1 期, 1–8.

[39] 何怀宏（2022）. 何以为人，人将何为? ——对人工智能等高科技的反思与展望［演讲稿］. 爱思想, 2022-11-26.

[40] Goertzel, B., & Pennachin, C. (Eds.) (2007). *Artificial General Intelligence*. Springer.

[41] Qin, R., Zhou, C., & He, M. (2025). A comprehensive taxonomy of machine consciousness. *Information Fusion*, 119, 102994.